

Séries Temporelles

Chapitre 3 : Les processus non stationnaires

Elena Dumitrescu

Université Panthéon-Assas

2024 - 2025

Plan

1 Introduction

2 DS versus TS

3 Les regressions falacieuses (factices)

4 Tests de racine unitaire

- Test de DF simple

- Les tests de DF augmenté (test ADF)

- Stratégie de test séquentielle

5 Les processus (s)ARIMA (suppl.)


6 Annexes

- Test de Phillips et Perron (1988)
- Test de stationnarité de KPSS (1992)

Introduction


- Beaucoup de séries économiques ne sont pas des processus stationnaires au second ordre
- La non-stationnarité peut se manifester au niveau de
 - l'espérance
 - la variance ou la covariance
- Plusieurs phénomènes peuvent mener à la non-stationnarité
 - ⇒ tendance déterministe
 - ⇒ saisonnalité
 - ⇒ tendance stochastique
 - ⇒ non-linéarités (dépassé le niveau M1)
 - ⇒ chocs de grandes valeurs et non-causalité (dépassé le niveau M1)
- Quelques exemples:
 - Inflation: Non-stationnarité globale/ locale? Racine unitaire?
 - Volatilité financière: Stationnarité? Non-stationnarité?

Variables macroéconomiques




- Difficile de déterminer visuellement si l'inflation est non-stationnaire
 - La fonction d'autocorrélation de l'inflation indique une très forte persistance
 - Pour autant, la série semble stable autour d'une moyenne de long terme

Variables financières




- Difficile de déterminer visuellement si la volatilité est non-stationnaire
 - La série est animée par de nombreux événements extrêmes
 - Pour autant, la série semble stable autour d'une moyenne de long terme

PIB - US



Séries journalière du CAC



Introduction

- Nelson et Plosser (1982) distinguent deux types de processus non-stationnaires :
 - les processus TS (pour **Trend stationary**)
 - les processus UR (pour **Unit root**) et dont la différence est stationnaire DS (**Difference stationary**)
- Stationnarisation : comment se ramener à un processus stationnaire à partir d'un processus non-stationnaire
- Pour chacun de ces deux types de processus : une méthode de stationnarisation spécifique
 - Processus TS : estimer puis soustraire la composante déterministe
 - Processus UR : différencier le processus autant de fois que nécessaire

Notion de régression fallacieuse

- Pourquoi mettre l'accent sur la notion de processus stationnaire ?
- La régression d'une variable UR sur une autre variable UR, sans rapport avec elle, peut produire à tort une relation faussement significative (spurious regression, c.f. section 3)

Comment faire la distinction entre des processus TS et UR ?

- Etude de la représentation graphique de la série
- Etude de l'autocorrélogramme
- Application de tests statistiques :
 - Test de racine unitaire de Dickey-Fuller
 - Test de racine unitaire de Phillips et Perron (annexe)
 - Test de stationnarité de Kwiatkovsky, Phillips, Schmidt and Shin (1992) (annexe)
- Remarque : trois principaux tests de racine unitaire et de stationnarité mais il en existe d'autres

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions fallacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Unit Root (UR) ou Trend Stationary (TS)?

Pour modéliser une série avec tendance, on peut envisager

- 1 un modèle **trend-stationnaire**

$$TS_t = DT(t) + MA_t,$$

où $DT(t)$ est une tendance déterministe et MA_t est un processus stationnaire avec une représentation $MA(\infty)$ de la forme $MA_t = \sum_{i \geq 0} c_i \varepsilon_{t-i}$,

- 2 un modèle à **racine unité**

$$(1 - B)UR_t = b + MA_t,$$

plus une valeur initiale $UR_0 = a$.

L'exemple le plus simple de processus à racine unité est la marche aléatoire $X_t = X_{t-1} + \varepsilon_t$

Un processus AR avec une seule racine égale à un et les autres à l'extérieur du cercle unité est l'exemple typique de processus à racine unité.

TS s'écarte moins de sa tendance que UR (annexe)

Pour simplifier supposons que

$$\text{TS}_t = a + bt + \text{MA}_t \quad \text{et} \quad (1 - B)\text{UR}_t = b + \varepsilon_t$$

avec $\text{UR}_0 = a$. Notons que

$$\text{UR}_t = b + \varepsilon_t + \text{UR}_{t-1} = 2b + \varepsilon_t + \varepsilon_{t-1} + \text{UR}_{t-2} = bt + a + \sum_{i=1}^t \varepsilon_i$$

Les moyennes sont identiques:

$$\mathbb{E}(\text{TS}_t) = \mathbb{E}(\text{UR}_t) = a + bt$$

Par contre

- $\text{var TS}_t = \text{var MA}_t = \sigma^2 \sum_{i \geq 0} c_i^2$ indépendant de t ,
- $\text{var UR}_t = \text{var} \sum_{i=1}^t \varepsilon_i = t\sigma^2 \rightarrow \infty$ quand $t \rightarrow \infty$.

Et les prévisions à long terme des UR sont très risquées...

Les prévisions à long terme du modèle TS (annexe)

Si le modèle TS est **inversible**, alors

$$\widehat{\text{TS}}_{t+h|t} = \text{DT}(t+h) + \widehat{\text{MA}}_{t+h|t} = \text{DT}(t+h) + \sum_{i \geq h} c_i \varepsilon_{t+h-i}.$$

On prévoit donc un rapprochement vers la tendance déterministe sur le long terme ("**mean reversion**").

De plus l'intervalle de prévision est borné même à horizon infini: en posant $\text{MSE}_X(h) = \mathbb{E}(X_{t+h} - \hat{X}_{t+h|t})^2$, on a

$$\text{MSE}_{\text{TS}}(h) = \text{var} \sum_{i=0}^{h-1} c_i \varepsilon_{t+h-i} = \sigma^2 \sum_{i=0}^{h-1} c_i^2 \rightarrow \sigma^2 \sum_{i=0}^{\infty} c_i^2 = \text{var TS}_t$$

quand $h \rightarrow \infty$.

Les prévisions à long terme du modèle UR sont très risquées (annexe)

Puisque $UR_{t+h} = \varepsilon_{t+h} + \dots + \varepsilon_{t+1} + bh + UR_t$, on a

$$\widehat{UR}_{t+h|t} = bh + UR_t,$$

c'est-à-dire que l'on prévoit une croissance régulière à la vitesse b à partir de la valeur courante, et

$$MSE_{UR}(h) = h\sigma^2 \rightarrow \infty$$


quand $h \rightarrow \infty$.

Effets des chocs

On peut interpréter l'innovation comme un **choc** (économique) à la date t .

Si $\varepsilon_t < 0$ alors une mauvaise nouvelle exogène a fait que la valeur observée X_t est moins bonne que la valeur attendue $\hat{X}_{t|t-1}$.


AR stationnaire (en bleu) et marche aléatoire (en rouge)



Le choc est modifié à la date $t = 25$. Les 100 dernières valeurs sont des prévisions encadrées par leurs intervalles de confiance.

http://perso.univ-lille3.fr/~cfrancq/Christian-Francq/Cours-ST-ENSAE/AR_UR.R

TS (en bleu) et UR (en rouge)



Les 100 dernières valeurs sont des prévisions encadrées par leurs intervalles de confiance, la tendance commune est en vert (retour à la moyenne pour TS)

http://perso.univ-lille3.fr/~cfrancq/Christian-Francq/Cours-ST-ENSAE/AR_UR.R

Interpretation économique

Si on pense que la série PNB suit un modèle TS, alors il faut admettre que l'effet d'un choc (pétrolier par exemple) finira par s'estomper complètement au cours du temps.

Si on croit à un modèle UR, alors on pense que l'économie ne rattrapera jamais complètement les pertes liées à une période de récession.

Les chocs sont persistants avec UR et temporaires avec TS (preuve en annexe)

Considérant X_{t+h} comme une fonction de tous les chocs ε_u , $u \leq t+h$, l'effet d'une petite variation du choc à la date t sur la valeur de X_{t+h} est donné par $\partial X_{t+h} / \partial \varepsilon_t$:

X_{t+h} variera de $\frac{\partial X_{t+h}}{\partial \varepsilon_t} \delta$ si ε_t augmente de δ , avec δ petit.

- L'effet d'un choc est **temporaire** pour TS:

$$\frac{\partial \text{TS}_{t+h}}{\partial \varepsilon_t} = \frac{\partial}{\partial \varepsilon_t} \left(\text{DT}(t+h) + \sum_{i \geq 0} c_i \varepsilon_{t+h-i} \right) = c_h \rightarrow 0$$

quand $h \rightarrow \infty$.

- Un choc est **persistant** pour UR: $(1-B)\text{UR}_t = b + \text{MA}_t$, $\text{UR}_0 = a$

$$\begin{aligned} \frac{\partial \text{UR}_{t+h}}{\partial \varepsilon_t} &= \frac{\partial}{\partial \varepsilon_t} \left(a + b(t+h) + \sum_{i=1}^{t+h} \text{MA}_i \right) \\ &= 1 + c_1 + \dots + c_h \rightarrow \sum_{i \geq 0} c_i. \end{aligned}$$

Exemple de processus TS

$$X_t = c + bt + \varepsilon_t$$

avec $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$

- $\mathbb{E}(X_t) = c + bt$
- L'espérance de X_t dépend du temps : non stationnarité déterministe
- ε_t est l'écart (aléatoire) par rapport à la composante déterministe
- Variance de X_t

$$\begin{aligned}\mathbb{V}(X_t) &= \mathbb{E} \left[(X_t - \mathbb{E}(X_t))^2 \right] \\ &= \mathbb{E}(\varepsilon_t^2) \\ &= \sigma_\varepsilon^2\end{aligned}$$

Exemple de processus TS -suite

■ Fonction d'autocovariance de X_t

$$\begin{aligned} \text{Cov}(X_t, X_{t+h}) &= \mathbb{E}[(X_t - \mathbb{E}(X_t))(X_{t+h} - \mathbb{E}(X_{t+h}))] \\ &= \mathbb{E}(\varepsilon_t \varepsilon_{t+h}) \\ &= 0, \forall h \neq 0 \end{aligned}$$

■ L'espérance est connue de façon certaine à chaque date t

■ L'effet d'un choc ε_t est transitoire

■ Retour à la tendance de long terme représentée par $c + bt$

Stationnarisation d'un processus TS

- La stationnarisation d'un processus TS consiste à estimer et extraire la composante déterministe :
 - 1 Si $X_t = c + bt + u_t$
 - 2 Estimation de c et b par les MCO
 - 3 Calcul de la série stationnarisée $\hat{u}_t = X_t - (\hat{c} + \hat{b}t)$
- Cette méthode se généralise à d'autres spécifications de la composante déterministe f_t comme :
 - $f_t = c + bt + dt^2$
 - Saisonnalité
 - Rupture dans la composante déterministe

Les processus UR : stationnaire en différence (DS)

- Un processus que l'on rend stationnaire en le différenciant autant de fois que nécessaire
- X_t n'est pas stationnaire, $\Delta^{d-1}X_t$ n'est pas stationnaire, mais $\Delta^d X_t = (1 - B)^d X_t$ est stationnaire :

$$\Delta^d X_t = (1 - B)^d X_t = b + u_t$$

où

- b est une constante
- u_t est un processus stationnaire
- d est l'ordre de différenciation du processus

Les processus UR : stationnaire en différence (DS)

- On dit aussi que X_t est intégré d'ordre d
- Notation $X_t \sim I(d)$
- Dans la pratique, on rencontre le plus souvent des processus $I(0)$, $I(1)$ ou $I(2)$
 - $X_t \sim I(0) \Rightarrow X_t$ est stationnaire
 - $X_t \sim I(1) \Rightarrow \Delta X_t = (1 - B)X_t - X_{t-1} \sim I(0)$
 - $X_t \sim I(2) \Rightarrow \Delta X_t = (1 - B)X_t - X_{t-1} \sim I(1)$ et
$$\Delta^2 X_t = (1 - B)^2 X_t = (1 - 2B + B^2)X_t = X_t - 2X_{t-1} + X_{t-2} \sim I(0)$$

Exemple 1: Marche aléatoire sans dérive

$$X_t = X_{t-1} + \varepsilon_t \Rightarrow X_t = X_0 + \sum_{i=1}^t \varepsilon_i \text{ avec } \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

- On stationnarise X_t est le différenciant une fois

$$\Delta X_t = (1 - L) X_t = \varepsilon_t \sim I(0)$$

- X_t est intégré d'ordre 1 : $X_t \sim I(1)$

Exemple 2 : Marche aléatoire avec dérive

$$X_t = b + X_{t-1} + \varepsilon_t \Rightarrow X_t = X_0 + bt + \sum_{i=1}^t \varepsilon_i$$

- b : coefficient de la tendance déterministe de X_t
- On a une non stationnarité déterministe (tendance déterministe) et stochastique (composante marche aléatoire)
- On note $\Delta X_t = b + \varepsilon_t \sim I(0) + C$
- Le terme C ici signifie que la série ΔX_t a une moyenne non nulle et que X_t contient une tendance déterministe

Comparaison des deux types de processus

■ On considère une série I(0) y_t et une série I(1) X_t :

- 1 $y_t = \phi_1 y_{t-1} + \varepsilon_{1t}$ avec $|\phi_1| < 1$ et $\varepsilon_{1t} \sim BB(0, \sigma_{\varepsilon_1}^2)$
- 2 $X_t = X_{t-1} + \varepsilon_{2t}$ avec $\varepsilon_{2t} \sim BB(0, \sigma_{\varepsilon_2}^2)$

Table: Tableau résumé des différences

Série	I(0)	I(1)
Variance	finie : $\frac{\sigma_{\varepsilon_1}^2}{(1-\phi_1^2)}$	non bornée : $t\sigma_{\varepsilon_2}^2$
Durée anticipée entre deux passages par la moyenne 0	finie	infinie
Mémoire	finie	infinie

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
- Les tests de DF augmenté (test ADF)
- Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Notion de régression fallacieuse

- Met en évidence l'importance de bien caractériser les processus DS, notamment pour la qualité des estimations
- De nombreuses séries macroéconomiques sont DS
- Les méthodes économétriques standards (comme les MCO) sont fondées sur l'hypothèse de séries stationnaires.
- Elles supposent que les moments empiriques de ces séries convergent vers leur vraie valeur finie
- Quand ces méthodes économétriques sont appliquées à des séries non stationnaires (DS) apparaît le risque de **régression fallacieuse** (ou "spurious regression", Granger et Newbold)

Exemple de régression fallacieuse

- La régression d'une variable DS sur une autre variable DS, sans rapport avec elle, peut produire à tort une relation faussement significative
- Ce résultat est indépendant de la taille de l'échantillon
- Illustration à partir d'un exercice de simulations de Monte-Carlo
- Soit le Data Generating Process (DGP) suivant :


$$\begin{cases} X_t = X_{t-1} + \varepsilon_t, \varepsilon_t \sim BB(0, \sigma_\varepsilon^2) \\ Y_t = Y_{t-1} + \nu_t, \nu_t \sim BB(0, \sigma_\nu^2) \end{cases}$$

avec $cov(\varepsilon_t, \nu_t) = 0$ et $X_0 = Y_0 = 0$.

- On génère I échantillons de taille T $\left\{ (X_t^i, Y_t^i) \right\}_{t=1, \dots, T}, i = 1, \dots, I$

Exemple de régression fallacieuse

- Soit une trajectoire de X_t et Y_t , deux marches aléatoires indépendantes



Exemple de régression fallacieuse

- On estime par les MCO la régression suivante :

$$Y_t^i = \beta_0 + \beta_1 X_t^i + u_t^i, t = 1, \dots, T \quad i = 1, \dots, I$$

- Par construction aucune relation entre Y_t et $X_t \Rightarrow$ la vraie valeur du paramètre $\beta_1 = 0$
- Résultats attendus de l'économétrie standard :
 - 1 $Plim \hat{\beta}_1 = \beta_1 = 0$
 - 2 Non-rejet de $H_0 : \beta_1 = 0$ dans des 5% cas avec un risque de première espèce égal à 5%.

Exemple de régression fallacieuse

■ Les simulations donnent les résultats suivants :

- 1 $\tilde{\beta}_1 = \frac{1}{T} \sum_{i=1}^T \hat{\beta}_1^i$ est significativement différent de 0.
 - 2 Dans 75% des cas, on rejette à tort l'hypothèse nulle $H_0 : \beta_1 = 0$ ce qui montre que la statistique de Student est biaisée.
 - 3 Le R^2 est artificiellement élevé et le DW bas
- L'application de l'estimateur des MCO à des séries non-stationnaires et non corrélées donne à croire qu'il existe une relation (artificielle) entre ces deux variables

Exemple de régression fallacieuse

■ Estimons le modèle

$$X_t = \beta_0 + \beta_1 Y_t + \varepsilon_t$$

pour lequel on s'attend à trouver $\hat{\beta}_1 = 0$

⇒ pourtant les résultats indiquent une relation significative

Included observations: 1000

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	9.557269	0.482904	19.79125	0.0000
Y	-0.700810	0.024364	-28.76363	0.0000
R-squared	0.453254	Mean dependent var		18.87462
Adjusted R-squared	0.452707	S.D. dependent var		15.30898
S.E. of regression	11.32547	Akaike info criterion		7.693984
Sum squared resid	128009.8	Schwarz criterion		7.703799
Log likelihood	-3844.992	Hannan-Quinn criter.		7.697714
F-statistic	827.3464	Durbin-Watson stat		0.011903
Prob(F-statistic)	0.000000			

Exemple de régression fallacieuse

- Estimons à présent le modèle

$$\Delta X_t = \beta_1 \Delta Y_t + u_t$$

pour lequel on s'attend à trouver $\hat{\beta}_1 = 0$

⇒ à présent on constate qu'il n'y a aucune relation entre X_t et Y_t

Included observations: 999 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.051278	0.031154	1.645935	0.1001
DY	0.035033	0.030722	1.140296	0.2544
R-squared	0.001302	Mean dependent var		0.050595
Adjusted R-squared	0.000301	S.D. dependent var		0.984653
S.E. of regression	0.984505	Akaike info criterion		2.808644
Sum squared resid	966.3420	Schwarz criterion		2.818467
Log likelihood	-1400.918	Hannan-Quinn criter.		2.812378
F-statistic	1.300276	Durbin-Watson stat		2.072721
Prob(F-statistic)	0.254437			

Conséquence d'une mauvaise stationnarisation

- La méthode de stationnarisation dépend de la nature du processus
 - Processus TS : estimation de la composante déterministe par les MCO puis stationnarisation par soustraction de cette composante
 - Processus UR : stationnarisation par différenciation autant de fois que nécessaire
- On examine les conséquences du choix d'une méthode de stationnarisation inadéquate

Conséquence sur un processus TS

Definition

La stationnarisation par différenciation d'un processus TS conduit à un processus avec une composante cyclique fausse

- Soit le processus TS : $X_t = \beta_0 + \beta_1 t + \varepsilon_t$ avec $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$
- D'où $\Delta X_t = X_t - X_{t-1} = \beta_1 + (\varepsilon_t - \varepsilon_{t-1}) = \beta_1 + \Delta \varepsilon_t$
- ΔX_t est donc un processus MA(1) avec une racine unitaire dans le polynôme MA
 ⇒ Il ne satisfait pas les conditions requises d'un processus MA
- De plus, ΔX_t présente un mouvement cyclique artificiel

Conséquence sur un processus TS

- Fonction d'autocovariance

$$\gamma(h) = cov(\Delta X_t, \Delta X_{t+h}) = cov(\varepsilon_t - \varepsilon_{t-1}, \varepsilon_{t+h} - \varepsilon_{t+h-1})$$

- Fonctions d'autocovariance $\gamma(h)$ et d'autocorrélation $\rho(h)$

$$\gamma(h) = \begin{cases} 2\sigma_\varepsilon^2, & si\ h = 0 \\ -\sigma_\varepsilon^2, & si\ h = 1 \\ 0 & si\ h > 1 \end{cases} \quad et \quad \rho(h) = \begin{cases} 1, & si\ h = 0 \\ -1/2, & si\ h = 1 \\ 0 & si\ h > 1 \end{cases}$$

- La différenciation de X_t induit un mouvement cyclique court **et artificiel** dans la série pseudo-stationnarisée
- Méthode de stationnarisation appropriée : estimer et enlever la composante déterministe
- Série correctement stationnarisée :

$$\varepsilon_t = X_t - (\beta_0 + \beta_1 t) \sim BB(0, \sigma_\varepsilon^2)$$

- ε_t est sans autocorrélation

Conséquence sur un processus DS

Definition

La stationnarisation par soustraction d'une tendance déterministe d'un processus DS conduit à un processus avec un mouvement pseudo-périodique

- La méthode de stationnarisation correcte consiste à appliquer un filtre en différence première
- Quelle conséquence si l'on applique la méthode préconisée pour un processus TS ?
- Cas d'une marche aléatoire $X_t = X_{t-1} + \varepsilon_t$
- Le processus stationnarisé par soustraction d'une tendance déterministe serait $\hat{\varepsilon}_t = X_t - (\hat{c} + \hat{b}t)$.
- $\hat{\varepsilon}_t$ présente une forte autocorrélation pour les premiers retards (soit un mouvement pseudo-périodique)
- Ce mouvement pseudo-périodique est d'autant plus élevé que le nombre d'observations de la chronique de départ est grand

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions fallacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Principe du test de racine unitaire

- Considérons un AR(1) simple

$$X_t = \phi_1 X_{t-1} + \varepsilon_t \text{ avec } \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

- Hypothèses du test

$$\begin{cases} H_0 : \phi_1 = 1 \Rightarrow X_t \text{ non stationnaire} \\ H_1 : |\phi_1| < 1 \Rightarrow X_t \text{ stationnaire} \end{cases}$$

- Dickey-Fuller ont proposé deux tests : DF et DF augmenté (ADF)
- Phillips-Perron ont proposé une alternative non-paramétrique d' ADF
- Kwiatkowski-Phillips-Schmidt-Shin ont proposé un test de stationnarité (KPSS)

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire**
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Principe du test de DF simple

■ Réécriture de l'équation

⇒ Régression de Dickey-Fuller simple

$$\begin{aligned} X_t &= \phi_1 X_{t-1} + \varepsilon_t \\ \Rightarrow X_t - X_{t-1} &= (\phi_1 - 1)X_{t-1} + \varepsilon_t \\ \Rightarrow \Delta X_t &= \rho X_{t-1} + \varepsilon_t, \text{ avec } \rho = \phi_1 - 1 \end{aligned}$$

⇒ Reformulation des hypothèses du test

$$\begin{cases} H_0 : \phi_1 = 1 \iff \rho = 0 \Rightarrow X_t \text{ non stationnaire (RU)} \\ H_1 : |\phi_1| < 1 \iff \rho < 0 \Rightarrow X_t \text{ stationnaire} \end{cases}$$

Mise en oeuvre du test de DF simple

- 1 Estimation de la régression de DF par les MCO :

$$\Delta X_t = \hat{\rho} X_{t-1} + \hat{\varepsilon}_t$$

- 2 **Statistique du test de DF simple** = statistique de “type” Student de $\hat{\rho}$

$$t_{\hat{\rho}} = \frac{\hat{\rho}}{\hat{\sigma}_{\hat{\rho}}} = \frac{\hat{\phi}_1 - 1}{\hat{\sigma}_{\hat{\phi}_1}}$$

- 3 Différence d'un test standard: sous H_0 , $t_{\hat{\rho}}$ **ne suit pas une loi normale standard**
- 4 Les seuils critiques sont disponibles dans **les tables de Dickey-Fuller**
- 5 Règle de décision : on rejette H_0 quand
 - la statistique de test $t_{\hat{\rho}}$ est plus petite que le seuil critique
 - quand la probabilité critique est inférieure au risque de première espèce choisi (1%, 5% ou 10 %)

DF critical values

Application au PIB des Etats-Unis

- PIB des Etats-Unis de 1990:1 à 2019:4 (120 observations)
- Série ajustée des variations saisonnières
- "Real Gross Domestic Product, Billions of Chained 2012 Dollars, Quarterly, [Seasonally Adjusted Annual Rate](#)"




Figure: PIB réel (en log) des Etats-Unis, 1990:1 à 2019:4

Série en niveau (non transformée) versus série en logarithme

- Le passage en logarithme (népérien) atténue le poids des observations extrême et contribue à lisser le profil de la série
- Rappel : la différence première de la série en log approxime le taux de croissance de X_t
- $x_t = \log(X_t)$
- $\Delta X_t = X_t - X_{t-1}$ = variation de la série en niveau

$$\begin{aligned}\Delta x_t = x_t - x_{t-1} &= \log\left(\frac{X_t}{X_{t-1}}\right) \\ &= \log\left(1 + \frac{\Delta X_t}{X_{t-1}}\right) \\ &\simeq \frac{\Delta X_t}{X_{t-1}}\end{aligned}$$

- ΔX_t est intéressant pour les séries macroéconomiques, les prix d'actifs financiers, les variables monétaires...

Application au PIB des Etats-Unis

Test de Dickey-Fuller pour l_GDP
 taille de l'échantillon 119
 hypothèse nulle de racine unitaire : $\alpha = 1$

test sans constante
 modèle: $(1-L)y = (\alpha-1)y(-1) + e$
 valeur estimée de $(\alpha - 1)$: 0,000632285
 statistique de test: $\tau_{nc}(1) = 11,2757$
 p. critique 1
 Coeff. d'autocorrélation du 1er ordre pour e: 0,400

Régression de Dickey-Fuller
 MCO, utilisant les observations 1990:2-2019:4 (T = 119)
 Variable dépendante: d_l_GDP

	coefficient	erreur std.	t de Student	p. critique
l_GDP_1	0,000632285	5,60748e-05	11,28	1,0000

AIC: -885,709 BIC: -882,93 HQC: -884,58

statistique du test de
Dickey-Fuller

probabilité critique du
test de Dickey-Fuller

Application au PIB des Etats-Unis

- Statistique du test de Dickey-Fuller simple

$$t_{DF} = t_{l_GDP_1} = 11.28$$

- Seuils critiques de la table de DF (T=100 observations)

α	1%	5%	10%
C_α	-2,60	-1,95	-1.61

- $t_{DF} = t_{l_GDP_1} = 11.28 > C_\alpha \Rightarrow$ on ne rejette pas l'hypothèse nulle de racine unitaire

Le test de Dickey-Fuller : cas général

- Dans la pratique il convient d'envisager la présence de
constante $\mu \neq 0$ et/ou trend déterministe $\delta \neq 0$

⇒ 3 modèles distincts sont alors envisageables

M(1) Le modèle le plus spécifique décrivant une simple marche aléatoire

$$\Delta X_t = \rho_1 X_{t-1} + \varepsilon_t$$

M(2) Le modèle sans tendance mais avec $\mu \neq 0$

$$\Delta X_t = \mu + \rho_2 X_{t-1} + \varepsilon_t$$

M(3) Le modèle le plus général, avec $\mu \neq 0$ et/ou $\delta \neq 0$

$$\Delta X_t = \mu + \delta t + \rho_3 X_{t-1} + \varepsilon_t$$

- Comme sous H_0 on a une racine unitaire, les distributions de

$$\hat{\rho}_1, \hat{\rho}_2, \hat{\rho}_3$$

sont non-standards, tout comme les distributions de

$$t_{\hat{\rho}_1} = \hat{\rho}_1 / \hat{\sigma}_\rho, \quad t_{\hat{\rho}_2} = \hat{\rho}_2 / \hat{\sigma}_\rho, \quad t_{\hat{\rho}_3} = \hat{\rho}_3 / \hat{\sigma}_\rho$$

et elles sont différentes selon le modèle (M1, M2 ou M3).

Le test de Dickey-Fuller : cas général

Modèle (1) sans constante ni tendance déterministe :

$$X_t = \phi_1 X_{t-1} + \varepsilon_t$$

- Sous H_1 , X_t est stationnaire avec $\mathbb{E}(X_t) = 0$ (pas de constante)
- Pas adapté à toutes les séries économiques :
 - Beaucoup de séries économiques ne sont pas nulles en moyenne
 - Des séries présentent une tendance à la hausse ou à la baisse pouvant suggérer l'existence d'une tendance déterministe

Exemple : l'évolution du PIB aux Etats-Unis (et dans d'autres pays)

Le test de Dickey-Fuller : cas général

Modèle (2) avec constante:

$$X_t = \phi_1 X_{t-1} + c + \varepsilon_t \text{ avec } \Rightarrow \Delta X_t = \rho X_{t-1} + c + \varepsilon_t$$

- Si la série est de moyenne non-nulle

Modèle (3) avec constante et tendance déterministe:

$$X_t = \phi_1 X_{t-1} + c + bt + \varepsilon_t \Rightarrow \Delta X_t = \rho X_{t-1} + c + bt + \varepsilon_t$$

,

- A utiliser si l'on pense que la série peut-être stationnaire autour d'une tendance déterministe

Le test de Dickey-Fuller : cas général

Pour chaque modèle (1), (2) et (3), on aura :

- les mêmes hypothèses de test,
- la même méthode d'estimation par les MCO,
- la même statistique de test,
- la même règle de décision (même interprétation de la probabilité critique)
- Les seuils critiques du test de DF dépendent du modèle estimé
- Interprétation inchangée de la probabilité critique

Table de Dickey-Fuller

7. TABLES DE DICKEY-FULLER¹

Modèle [1] sans tendance et sans terme constant

Modèle [2] sans tendance et avec terme constant

Modèle [3] avec tendance et avec terme constant

Nombre observations	Probabilités							
<i>n</i>	0,01	0,025	0,05	0,10	0,90	0,95	0,975	0,99
25	-2,66	-2,26	-1,95	-1,60	0,92	1,33	1,70	2,16
50	-2,62	-2,25	-1,95	-1,61	0,91	1,31	1,66	2,08
100	-2,60	-2,4	-1,95	-1,61	0,91	1,29	1,64	2,03
250	-2,58	-2,23	-1,95	-1,62	0,89	1,29	1,63	2,01
500	-2,58	-2,23	-1,95	-1,62	0,89	1,28	1,62	2,00
∞	-2,58	-2,23	-1,95	-1,62	0,89	1,28	1,62	2,00
25	-3,75	-3,33	-3,00	-2,63	-0,37	0,00	0,34	0,72
50	-3,58	-3,22	-2,93	-2,60	-0,40	-0,03	0,29	0,66
100	-3,51	-3,17	-2,89	-2,58	-0,42	-0,05	0,26	0,63
250	-3,46	-3,14	-2,88	-2,57	-0,42	-0,06	0,24	0,62
500	-3,44	-3,13	-2,87	-2,57	-0,43	-0,07	0,24	0,61
∞	-3,43	-3,12	-2,86	-2,57	-0,44	-0,07	0,23	0,60
25	-4,38	-3,95	-3,60	-3,24	-1,14	-0,80	-0,50	-0,15
50	-4,15	-3,80	-3,50	-3,18	-1,19	-0,87	-0,58	-0,24
100	-4,04	-3,73	-3,45	-3,15	-1,22	-0,90	-0,62	-0,28
250	-3,99	-3,69	-3,43	-3,13	-1,23	-0,92	-0,64	-0,31
500	-3,98	-3,68	-3,42	-3,13	-1,24	-0,93	-0,65	-0,32
∞	-3,96	-3,66	-3,41	-3,12	-1,25	-0,94	-0,66	-0,33

Modèle [1]

Modèle [2]

Modèle [3]

Remarque : test de bulle spéculative (annexe)

Il peut également être intéressant de faire un test unilatéral à droite sur une série de prix ou un indice boursier :

$$H_0 : \phi = 1$$

$$H_1 : \phi > 1$$

Sous H_1 , la dynamique du prix est explosive (bulle spéculative).

Voir PCB Phillips, S. Shi, and J. Yu (2014). *Specification Sensitivity in Right-Tailed Unit Root Testing for Explosive Behaviour*. *Oxford Bulletin of Economics and Statistics*, pp. 315-333 : tests sur des plages temporelles récursives

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire**
 - Test de DF simple
 - **Les tests de DF augmenté (test ADF)**
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Les tests de DF augmenté (test ADF)

- Test de DF **simple** fondé sur l'hypothèse $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$

⇒ Hypothèse trop forte

- Pour prendre en compte le problème, il y a globalement deux solutions :
 - 1 on modifie le modèle de façon à blanchir les résidus (test ADF)
 - 2 on corrige la statistique de test (test PP)
- Les tables de Dickey-Fuller sont valables uniquement dans le cas où le terme d'erreur ε_t est un bruit blanc.
- Si ε_t n'est pas un bruit blanc, on risque de fausser les résultats du test.
- Nécessaire de considérer un modèle plus général prenant en compte cette autocorrélation et permettant d'utiliser ces tables de Dickey-Fuller.
- Une façon de se ramener à un ε_t sans autocorrélation consiste à ajouter des variables en différence première retardées $\Delta X_{t-1}, \Delta X_{t-2}, \dots, \Delta X_{t-p}$ à la régression de Dickey-Fuller ⇒ test ADF preuve ADF

Test de DF augmenté

Modèle (4) sans constante

$$\Delta X_t = \rho X_{t-1} + \sum_{j=1}^p \gamma_j \Delta X_{t-j} + \varepsilon_t$$

Modèle (5) avec constante

$$\Delta X_t = c + \rho X_{t-1} + \sum_{j=1}^p \gamma_j \Delta X_{t-j} + \varepsilon_t$$

Modèle (6) avec constante et tendance déterministe

$$\Delta X_t = c + bt + \rho X_{t-1} + \sum_{j=1}^p \gamma_j \Delta X_{t-j} + \varepsilon_t$$

Test ADF : mise en oeuvre

La procédure du test ADF est identique à celle du test DF

- Mêmes hypothèses que pour le test de DF simple

$$\begin{cases} H_0 : \rho = 0 \Rightarrow X_t \text{ non stationnaire} \\ H_1 : \rho < 0 \Rightarrow X_t \text{ stationnaire} \end{cases}$$

- Estimation de la régression de Dickey-Fuller Augmentée par les MCO
- Statistique du test de Dickey-Fuller Augmenté :

$$t_{\hat{\rho}} = \frac{\hat{\rho}}{\hat{\sigma}_{\hat{\rho}}} = \frac{\hat{\phi}_1 - 1}{\hat{\sigma}_{\hat{\phi}_1}}$$

- Utilisation des seuils critiques de DF simple

Test ADF : choix de p

Il est néanmoins crucial ici de **déterminer p auparavant**

■ Contrôler ex-post l'absence d'autocorrélation des résidus

1.a. Estimer le modèle

$$\Delta X_t = \mu + \delta t + \phi X_{t-1} + \sum_{j=1}^{pmax} \zeta_j \Delta X_{t-j} + \varepsilon_t$$

1.b. Contrôler la présence d'auto-corrélation sérielle des résidus (test de Ljung-Box)

1.c. Si les résidus sont auto-corrélés on augmente $pmax$

1.d. Si les résidus sont non auto-corrélés on teste avec $p < pmax$

1.e. On garde le plus petit p qui satisfait 1.d. et on passe à l'étape 1.a.

Note L'utilisation des critères de sélection est aussi possible

2.a. On choisit un nombre de retards maximum $pmax$

2.b. On estime la régression de Dickey-Fuller augmentée en faisant varier p de 0 à $pmax$.

2.c. On retient le nombre de retards qui minimise l'un des 3 critères d'information : AIC, BIC, HQ

La procédure ADF en présence d'ARMA(p, q)

- La procédure du test ADF reste identique
- ⇒ Elle repose sur la représentation $AR(\infty)$ des $ARMA(p, q)$
- Il faut chercher l'**approximation** par un $AR(p < \infty)$
 - Dans ce contexte les critères AIC ou BIC sont à privilégier

Note La procédure de sélection de p est importante pour que

$$\hat{\tau}_1, \hat{\tau}_2, \hat{\tau}_3$$

possèdent les distributions (non-standard) attendues

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire**
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - **Stratégie de test séquentielle**
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)


Stratégie de test séquentielle

Objectif : caractériser la nature d'une série : stationnaire ou non stationnaire

- Quelle composante déterministe :
 - constante et tendance déterministe
 - constante
 - pas de constante ni de tendance déterministe

Démarche : du modèle le plus général au modèle le plus particulier

Idée : il vaut mieux une variable superflue (pas significative le plus souvent) qu'une variable omise



Exemple : caractérisation du PIB des Etats-Unis

Etape 1 : Test ADF Modèle 3 avec constante et tendance déterministe

- On choisi $pmax = 10$ le nombre de retards maximum
- Nombre de retards optimal = 2 (utilisation du critère AIC)

Test de Dickey-Fuller augmenté pour l_GDP
testing down from 10 lags, criterion AIC
taille de l'échantillon 117
hypothèse nulle de racine unitaire : $a = 1$

10 retards au maximum,
critère AIC

avec constante et tendance temporelle
avec 2 retards de $(1-L)l_GDP$
modèle: $(1-L)y = b_0 + b_1t + (a-1)y(-1) + \dots + e$
valeur estimée de $(a-1)$: -0,0183347
statistique de test: $\tau_{ct}(1) = -1,50956$
p. critique asymptotique 0,8267
Coeff. d'autocorrélation du 1er ordre pour e: -0,035
différences retardées: $F(2, 112) = 12,746 [0,0000]$

Nombre de retards optimal = 2

Statistique de test

Régression du test de Dickey-Fuller augmenté
MCO, utilisant les observations 1990:4-2019:4 (T = 117)
Variable dépendante: d_l_GDP

	coefficient	erreur std.	t de Student	p. critique	
const	0,171953	0,111172	1,547	0,1247	
l_GDP_1	-0,0183347	0,0121457	-1,510	0,8267	
d_l_GDP_1	0,305915	0,0914127	3,347	0,0011	***
d_l_GDP_2	0,205775	0,0917889	2,242	0,0269	**
time	9,51904e-05	7,53986e-05	1,262	0,2094	

AIC: -890,947 BIC: -877,136 HQC: -885,34

■ Statistique du test ADF = $t_{\hat{\rho}} = t_{l_GDP_1} = -1.510$

■ Seuils critiques

α	1%	5%	10%
C_α	-4,04	-3,45	-3,15

■ $t_{\hat{\rho}} = -1.510 > C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: on ne rejette pas l'hypothèse nulle de racine unitaire

■ On vérifie *ensuite* la significativité de la tendance déterministe

■ $|t_{time}| = 1.262$ à comparer aux seuils critiques pour t_b

α	2%	5%	10%
C_α	3.53	3,14	2.79

■ $|t_{time}| = 1.262 < C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: (le coefficient de) la tendance déterministe n'est pas significativement différente de 0

■ On passe au modèle 2 avec constante

Etape 2 : Test ADF Modèle 2 avec constante

- Nombre de retards optimal = 2 (utilisation du critère AIC)

```
test avec constante
avec 2 retards de (1-L)l_GDP
modèle: (1-L)y = b0 + (a-1)*y(-1) + ... + e
valeur estimée de (a - 1): -0,00329257
statistique de test: tau_c(1) = -1,39257
p. critique asymptotique 0,5876
Coeff. d'autocorrélation du 1er ordre pour e: -0,029
différences retardées: F(2, 113) = 12,028 [0,0000]
```

Régression du test de Dickey-Fuller augmenté
MCO, utilisant les observations 1990:4-2019:4 (T = 117)
Variable dépendante: d_l_GDP

	coefficient	erreur std.	t de Student	p. critique	
const	0,0345287	0,0226547	1,524	0,1303	
l_GDP_1	-0,00329257	0,00236438	-1,393	0,5876	
d_l_GDP_1	0,300891	0,0915657	3,286	0,0014	***
d_l_GDP_2	0,190937	0,0912723	2,092	0,0387	**

AIC: -891,293 BIC: -880,245 HQC: -886,808

■ Statistique du test ADF = $t_{\hat{\rho}} = t_{l_GDP_1} = -1.393$

■ Seuils critiques

α	1%	5%	10%
C_α	-3.51	-2.89	-2.58

■ $t_{\hat{\rho}} = -1.393 > C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: on ne rejette pas l'hypothèse nulle de racine unitaire

■ On vérifie *ensuite* la significativité de la constante

■ $|t_{const}| = 1.524$ à comparer aux seuils critiques pour t_c

α	2%	5%	10%
C_α	3.22	2.86	2.54

■ $|t_{const}| = 1.524 < C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: la constante n'est pas significativement différente de 0

■ On passe au modèle 1 sans constante ni tendance déterministe

Etape 3: Test ADF Modèle 1 sans constante ni tendance déterministe

- Nombre de retards optimal = 2 (utilisation du critère AIC)

```
test sans constante
avec 2 retards de (1-L)l_GDP
modèle: (1-L)y = (a-1)*y(-1) + ... + e
valeur estimée de (a - 1): 0,000308929
statistique de test: tau_nc(1) = 3,77641
p. critique asymptotique 1
Coeff. d'autocorrélation du 1er ordre pour e: -0,021
différences retardées: F(2, 114) = 13,694 [0,0000]
```

Régression du test de Dickey-Fuller augmenté
MCO, utilisant les observations 1990:4-2019:4 (T = 117)
Variable dépendante: d_l_GDP

	coefficient	erreur std.	t de Student	p. critique	
l_GDP_1	0,000308929	8,18050e-05	3,776	1,0000	
d_l_GDP_1	0,316805	0,0914948	3,463	0,0008	***
d_l_GDP_2	0,202619	0,0914761	2,215	0,0287	**

AIC: -890,913 BIC: -882,626 HQC: -887,548

■ Statistique du test ADF = $t_{\hat{\rho}} = t_{l_{GDP_1}} = 3.776$

■ Seuils critiques

α	1%	5%	10%
C_{α}	-2.60	-1.95	-1.61

■ $t_{\hat{\rho}} = 3.776 > C_{\alpha}$ pour $\alpha = 1\%, 5\%, 10\%$: on ne rejette pas l'hypothèse nulle de racine unitaire

■ On conclut que le PIB US est un processus DS sans dérive

■ On vérifie que le PIB en différence première est stationnaire

```
test avec constante
avec un retard de (1-L)d_1_GDP
modèle: (1-L)y = b0 + (a-1)*y(-1) + ... + e
valeur estimée de (a - 1): -0,486687
statistique de test: tau_c(1) = -4,83979
p. critique asymptotique 4,293e-005
Coeff. d'autocorrélation du 1er ordre pour e: -0,022
```

Régression du test de Dickey-Fuller augmenté
MCO, utilisant les observations 1990:4-2019:4 (T = 117)
Variable dépendante: d_d_1_GDP

	coefficient	erreur std.	t de Student	p. critique	
const	0,00299916	0,000782522	3,833	0,0002	***
d_1_GDP_1	-0,486687	0,100559	-4,840	4,29e-05	***
d_d_1_GDP_1	-0,199752	0,0914269	-2,185	0,0309	**

AIC: -891,303 BIC: -883,016 HQC: -887,938

- $t_{\hat{\rho}} = -4.84 < -3.51$ seuil critique pour $\alpha = 1\%$: rejet de l'hypothèse nulle de racine unitaire
- $t_{const} = 3.822 > 1.96$: constante significativement différente de 0
- PIB en différence première : stationnaire de moyenne non nulle : ARMA(p,q)
- Le PIB des Etats-Unis est un processus I(1) (ou DS sans dérive) : ARIMA(p,d,q) avec d=1

Conclusion sur les tests de Dickey-Fuller

- Test de Dickey-Fuller augmenté : le plus connu des test de racine unitaire
- Il existe d'autres tests qui se distinguent :
 - par la façon dont ils résolvent l'autocorrélation des termes d'erreur ε_t (exemple: test de Phillips et Perron)
 - dont ils traitent la composante déterministe

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Introduction

Si les données présentent aucune non stationnarité apparente et une fonction d'autocorrélation décroissant rapidement, on essaye d'ajuster un modèle ARMA sur la série corrigée de sa moyenne

Sinon, on cherche une transformation permettant de se ramener au cas précédent. Si la série présente une tendance stochastique mais pas de saisonnalité, il suffit en général d'une différenciation

On est conduit à considérer la classe des ARMA intégrés, ou ARIMA

Modèles ARMA intégrés

Définition

Si d est un entier positif ou nul, une série (X_t) est un $\text{ARIMA}(p, d, q)$ si la série

$$Y_t = (1 - B)^d X_t$$

est un $\text{ARMA}(p, q)$ causal.

On a donc

$$\phi(B)(1 - B)^d X_t = \psi(B)\varepsilon_t, \quad \varepsilon_t \sim \text{BB}(0, \sigma^2)$$

où ϕ est un polynôme de degré p dont les racines sont de module > 1 et ψ est un polynôme de degré q .

Notez que (X_t) n'est **stationnaire** que si $d = 0$.

Remarques

Si $d \geq 1$ on peut ajouter à X_t n'importe quel **polynôme de degré $d - 1$** sans changer le modèle. Les ARIMA sont donc adaptés pour les séries avec tendance

L'estimation des paramètres se fera à partir des propriétés de la série différenciée $(1 - B)^d X_t$. Des hypothèses supplémentaires seront nécessaires pour la prévision

Les ARIMA peuvent également être appropriés pour des séries sans tendance déterministe (une marche aléatoire par exemple)


Prévision: la recoloration

- La prévision est calculée pour la variable stationnarisée
- Recoloration = calcul de la prévision pour la variable initiale non stationnarisé
- Cas d'un processus DS : $X_t = \Delta z_t$
 - La prévision en t de z_{t+1} sera : $z_t^a(1) = z_t + X_t^a(1) = z_t + \Delta_t^a z_t(1)$.
 - Pour les horizons de prévision $h > 1$, on aura $z_t^a(h) = z_t^a(h-1) + X_t^a(h) = z_t + \Delta_t^a z_t(h)$
- Cas d'un processus TS
 - $z_t = a + bt + X_t$ le processus TS
 - Le processus stationnarisé X_t est modélisé à l'aide d'un modèle ARMA.
 - La prévision en t de z_{t+h} sera : $z_t^a(h) = a + b(t+h) + X_t^a(h), \forall h > 0$.

Saisonnalité

Les séries saisonnières sont caractérisées par de **fortes autocorrélations** et autocorrélations partielles empiriques entre les variables décalées d'une ou plusieurs **saisons**.

- La saisonnalité stochastique n'implique pas la non-stationnarité
 - ⇒ mais s'analyse à travers un modèle général : Seasonal ARIMA
- e.g. les ventes mensuelles de vin montrent une forte saisonnalité
 - ⇒ pic en juillet et creux en janvier en plus d'une tendance haussière



Dépendance saisonnière

- La dépendance au passé sera donc importante à 12 mois

$$\rho_{12}, \rho_{24}, \rho_{36}, \dots$$

entre juillet (janvier) de l'année en cours et l'année passée

⇒ Un modèle $\text{ARMA}(P, Q)_s$ troué de **span** $s = 12$ sera approprié

e.g. 1 dans le cas d'un $\text{MA}(1)_{12}$ on aura

$$X_t = (1 + \theta_1 L^{12})\varepsilon_t \Leftrightarrow X_t = \varepsilon_t + \theta_1 \varepsilon_{t-12}$$

e.g. 2 dans le cas d'un $\text{AR}(1)_{12}$ on aura

$$(1 - \varphi_1 L^{12})X_t = \varepsilon_t \Leftrightarrow X_t = \varphi_1 X_{t-12} + \varepsilon_t$$

Note Le span dépend de la fréquence :

$s = 2$ (semestriel), $s = 4$ (trimestriel), $s = 52$ (hebdomadaire)

Filtre saisonnier et SARMA

- Après application d'un $\text{ARMA}(P, Q)_s$, une dépendance peut rester
- L' $\text{ARMA}(P, Q)_s$ agit comme un filtre qui retourne Y_t

$$\Phi(L)_s X_t = \Theta(L)_s Y_t$$

- Un second filtre de type $\text{ARMA}(p, q)$ est donc nécessaire

$$\Phi(L) Y_t = \Theta(L) \varepsilon_t$$

afin que la dépendance disparaisse et de récupérer $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$

⇒ Le produit des deux filtres donne le modèle $\text{SARMA}(p, q) \times (P, Q)_s$

$$\Phi(L)\Phi(L)_s X_t = \Theta(L)\Theta(L)_s \varepsilon_t$$

Note Les conditions de stationnarité et inversibilité usuelles s'appliquent

Modèle global SARIMA

Définition:

On appelle processus $SARIMA_s[(p, d, q), (P, D, Q)]$ de période s tout processus (X_t) tel que le processus

$$Y_t = (I - L)^d (I - L_s)^D X_t$$

est un ARMA causal

$$\Phi(L)\Phi(L_s)Y_t = \Psi(L)\Psi(L_s)\varepsilon_t$$

où $\Phi, \Phi_s, \Psi, \Psi_s$ sont des polynômes de degrés p, P, q, Q respectivement.

- Pour identifier les ordres P et Q on examine les autocorrélations et autocorrélations partielles empiriques de (Y_t) aux retards multiples de s
- Pour p, P, q, Q, d fixés les paramètres des polynômes ϕ, Φ, ψ, Ψ et σ^2 peuvent être estimés par MCO.
- La série (Y_t) est un $ARMA(p + sP, q + sQ)$ dont certains coefficients sont nuls.

Plan

1 Introduction

2 DS versus TS

3 Les regressions falacieuses (factices)

4 Tests de racine unitaire

- Test de DF simple

- Les tests de DF augmenté (test ADF)

- Stratégie de test séquentielle

5 Les processus (s)ARIMA (suppl.)

6 Annexes

- Test de Phillips et Perron (1988)
- Test de stationnarité de KPSS (1992)

Table de Dickey-Fuller

7. TABLES DE DICKEY-FULLER¹
Modèle [1] sans tendance et sans terme constant
Modèle [2] sans tendance et avec terme constant
Modèle [3] avec tendance et avec terme constant

Nombre observations	Probabilités								
<i>n</i>	0,01	0,025	0,05	0,10	0,90	0,95	0,975	0,99	
25	− 2,66	− 2,26	− 1,95	− 1,60	0,92	1,33	1,70	2,16	Modèle [1]
50	− 2,62	− 2,25	− 1,95	− 1,61	0,91	1,31	1,66	2,08	
100	− 2,60	− 2,4	− 1,95	− 1,61	0,91	1,29	1,64	2,03	
250	− 2,58	− 2,23	− 1,95	− 1,62	0,89	1,29	1,63	2,01	
500	− 2,58	− 2,23	− 1,95	− 1,62	0,89	1,28	1,62	2,00	
∞	− 2,58	− 2,23	− 1,95	− 1,62	0,89	1,28	1,62	2,00	
25	− 3,75	− 3,33	− 3,00	− 2,63	− 0,37	0,00	0,34	0,72	Modèle [2]
50	− 3,58	− 3,22	− 2,93	− 2,60	− 0,40	− 0,03	0,29	0,66	
100	− 3,51	− 3,17	− 2,89	− 2,58	− 0,42	− 0,05	0,26	0,63	
250	− 3,46	− 3,14	− 2,88	− 2,57	− 0,42	− 0,06	0,24	0,62	
500	− 3,44	− 3,13	− 2,87	− 2,57	− 0,43	− 0,07	0,24	0,61	
∞	− 3,43	− 3,12	− 2,86	− 2,57	− 0,44	− 0,07	0,23	0,60	
25	− 4,38	− 3,95	− 3,60	− 3,24	− 1,14	− 0,80	− 0,50	− 0,15	Modèle [3]
50	− 4,15	− 3,80	− 3,50	− 3,18	− 1,19	− 0,87	− 0,58	− 0,24	
100	− 4,04	− 3,73	− 3,45	− 3,15	− 1,22	− 0,90	− 0,62	− 0,28	
250	− 3,99	− 3,69	− 3,43	− 3,13	− 1,23	− 0,92	− 0,64	− 0,31	
500	− 3,98	− 3,68	− 3,42	− 3,13	− 1,24	− 0,93	− 0,65	− 0,32	
∞	− 3,96	− 3,66	− 3,41	− 3,12	− 1,25	− 0,94	− 0,66	− 0,33	

Table des seuils critiques pour la constante et la tendance déterministe

Table de la distribution des t_c et t_b (test bilatéral)

	Modèle [2]			Modèle [3]					
	Constante c			Constante c			Tendance b		
n	2 %	5 %	10 %	2 %	5 %	10 %	2 %	5 %	10 %
25	3,41	2,97	2,61	4,05	3,59	3,20	3,74	3,25	2,85
50	3,28	2,89	2,56	3,87	3,47	3,14	3,60	3,18	2,81
100	3,22	2,86	2,54	3,78	3,42	3,11	3,53	3,14	2,79
250	3,19	2,84	2,53	3,74	3,39	3,09	3,49	3,12	2,79
500	3,18	2,83	2,52	3,72	3,38	3,08	3,48	3,11	2,78
∞	3,18	2,83	2,52	3,71	3,38	3,08	3,46	3,11	2,78

Preuve ADF

Considérons $X \sim AR(1)$ avec des innovations autocorrélées à l'ordre $p - 1$

$$X_t = \phi X_{t-1} + \varepsilon_t,$$

$$\varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_{t-p} \varepsilon_{t-p+1} = \mu_t,$$

avec $\mu_t \text{ i.i.d.}(0, \sigma_\mu^2)$

En substituant ε_t par l'expression $X_t - \phi X_{t-1}$, on obtient

$$\begin{aligned} \mu_t &= X_t - \phi X_{t-1} + \theta_1(X_{t-1} - \phi X_{t-2}) + \theta_2(X_{t-2} - \phi X_{t-3}) + \dots + \theta_{p-1}(X_{t-p+1} - \phi X_{t-p}) \\ &= X_t + (\theta_1 - \phi)X_{t-1} + (\theta_2 - \phi\theta_1)X_{t-2} + \dots + (\theta_{p-1} - \phi\theta_{p-2})X_{t-p+1} - \phi\theta_{p-1}X_{t-p} \end{aligned} \tag{1}$$

Donc le processus $X \sim AR(1)$ avec des innovations autocorrélées à l'ordre $p - 1$ est equivalent à un $AR(p)$

$$X_t = \psi_1 X_{t-1} + \psi_2 X_{t-2} + \dots \psi_p X_{t-p} + \mu_t,$$

avec $\psi_1 = -(\theta_1 - \phi)$, $\psi_i = -(\theta_i - \phi\theta_{i-1})$, pour $i = 2, \dots, p - 1$, et $\psi_p = \phi\theta_{p-1}$.

Ainsi, la représentation $AR(1)$ avec autocorrélation des innovation est transformée en une représentation $AR(p)$ où les innovations sont des bruits blancs

La spécification utilisée pour le test ADF est basée sur la représentation de Sims, Stock et Watson (1990) qui inclut $p - 1$ termes différenciés retardés :

$$X_t = \psi_1 X_{t-1} + \psi_2 X_{t-2} + \dots \psi_p X_{t-p} + \mu_t,$$

qui est equivalente avec la forme suivante

$$X_t = \rho X_{t-1} + \gamma_1 \Delta X_{t-1} + \gamma_2 \Delta X_{t-2} + \dots \gamma_{p-1} \Delta X_{t-(p-1)} + \mu_t,$$

où γ_j est l'opposé de la somme partielle des coefficients $\forall j = 1, 2, 3, \dots, p - 1$

$$\gamma_j = -(\psi_{j+1} + \psi_{j+2} + \dots + \psi_p)$$

$$\rho = -\gamma_0 = \psi_1 + \psi_2 + \dots + \psi_p$$

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes**
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Test de Phillips et Perron

- Test comparable au test ADF
- Une autre méthode de correction de l'autocorrélation et l'hétéroscédasticité du terme d'erreur.
- **Etape 1 :** Estimation par les MCO de la régression de Dickey-Fuller simple
 - modèle (1) : $\Delta X_t = \hat{\rho}X_{t-1} + \hat{\varepsilon}_t$
 - modèle (1) : $\Delta X_t = \hat{c} + \hat{\rho}X_{t-1} + \hat{\varepsilon}_t$
 - modèle (1) : $\Delta X_t = \hat{c} + \hat{b}t + \hat{\rho}X_{t-1} + \hat{\varepsilon}_t$

■ **Etape 2 :** tranformation de la statistique du test de DF simple pour la rendre comparable aux seuils critiques de la table de DF.

- Estimation de la variance de $\hat{\varepsilon}_t$: $\hat{\sigma}_{\varepsilon}^2 = \frac{1}{T} \sum_{t=1}^T \hat{\varepsilon}_t^2$
- Estimation d'un facteur correctif s_l^2 appelé variance de long terme

$$\hat{s}_{\varepsilon}^2 = \frac{1}{T} \sum_{t=1}^T \hat{\varepsilon}_t^2 + 2 \sum_{i=1}^l \left(1 - \frac{i}{l+1}\right) \frac{1}{T} \sum_{t=i+1}^T \hat{\varepsilon}_t \hat{\varepsilon}_{t-i}$$

où le paramètre $l = 4(T/100)^{2/9}$ par exemple.

- Statistique du test de Phillips et Perron

$$t_{\hat{\Phi}_1}^* = \sqrt{k} \frac{\hat{\Phi}_1 - 1}{\hat{\sigma}_{\hat{\Phi}_1}} + \frac{T(k-1)\hat{\sigma}_{\hat{\Phi}_1}}{2\sqrt{k}}$$

avec $k = \frac{\hat{\sigma}_{\varepsilon}^2}{\hat{s}_{\varepsilon}^2}$

- Statistique du test de Phillips et Perron $t_{\hat{\Phi}_1}^*$ à comparer aux seuils critiques de la table de DF simple
- Même règle de décision que le test DF : on rejette H_0 quand
 - la statistique de test $t_{\hat{\rho}}$ est plus petite que le seuil critique.
 - la probabilité critique est inférieure au risque de première espèce choisi (1%, 5% ou 10 %)
- Remarque : si ε_t est un bruit blanc $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$,
 - $k = 1 \Rightarrow$ la statistique du test PP devient la statistique du test de DF simple

$$t_{\hat{\Phi}_1}^* = \frac{\hat{\Phi}_1 - 1}{\hat{\sigma}_{\hat{\Phi}_1}}$$

- En l'absence d'autocorrélation et d'hétéroscédasticité, la statistique du test DF simple ne doit pas être très différente de celle du test de Phillips et Perron
- La stratégie de test s'applique comme pour le test ADF

Application du PP test au PIB des U.S.

Phillips-Perron unit-root test for l_GDP, Bartlett bandwidth 4:

$Z_t = -1,10633$ (p-value = 0,9230)

Test regression (OLS, dependent variable l_GDP, T = 119):

	coefficient	erreur std.	z	p. critique	
const	0,0956198	0,120646	0,7926	0,4280	
time	3,40531e-05	8,16738e-05	0,4169	0,6767	
l_GDP(-1)	0,990383	0,0131727	75,18	0,0000	***
Sample variance of residual		3,34373e-005			
Estimated long-run error variance		7,02598e-005			

Statistique du test de Phillips et Perron = $Z_t = -1.10$ à comparer aux seuils critiques de la table de Dickey-Fuller

α	1%	5%	10%
C_α	-4,04	-3,45	-3,15

$Z_t = -1.10 > C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: on ne rejette pas l'hypothèse nulle de racine unitaire

Test de Phillips et Perron avec constante

```
Phillips-Perron unit-root test for l_GDP, Bartlett bandwidth 4:
Z_t = -1,27708 (p-value = 0,6386)

Test regression (OLS, dependent variable l_GDP, T = 119):
```

	coefficient	erreur std.	z	p. critique	
const	0,0462999	0,0236400	1,959	0,0502	*
l_GDP(-1)	0,995776	0,00248002	401,5	0,0000	***

```
Sample variance of residual      3,32012e-005
Estimated long-run error variance 7,00467e-005
```

Statistique du test de Phillips et Perron = $Z_t = -1.27$ à comparer aux seuils critiques de la table de Dickey-Fuller

α	1%	5%	10%
C_α	-3.51	-2.89	-2.58

$Z_t = -1.27 > C_\alpha$ pour $\alpha = 1\%, 5\%, 10\%$: on ne rejette pas l'hypothèse nulle de racine unitaire

Remarques

- On ne connaît pas a priori la forme de la composante déterministe de la série (présence d'une tendance déterministe ou pas)
- On peut exclure le cas sans constante car la moyenne de la série est différente de 0
- Pour chacune des formes de composante déterministe, on ne rejette pas l'hypothèse nulle de racine unitaire
- L'hypothèse de racine unitaire est donc robuste à la présence d'une tendance déterministe ou non

Remarques

- Dans chacune des régressions, la statistique du test de DF simple est différente de celle du test de Phillips et Perron :

	Z_t	$t_{\hat{\rho}}$
Modèle 2	-1.27	401.5
Modèle 3	-1.10	75.18

- Cette différence justifie l'utilisation du test de Phillips et Perron : il est nécessaire de corriger l'autocorrélation et l'hétéroscédasticité des résidus

Plan

- 1 Introduction
- 2 DS versus TS
- 3 Les regressions falacieuses (factices)
- 4 Tests de racine unitaire
 - Test de DF simple
 - Les tests de DF augmenté (test ADF)
 - Stratégie de test séquentielle
- 5 Les processus (s)ARIMA (suppl.)
- 6 Annexes**
 - Test de Phillips et Perron (1988)
 - Test de stationnarité de KPSS (1992)

Test de stationnarité de KPSS

Problème : les tests minimisent en priorité le risque de 1ère espèce, i.e. dans les tests précédents le rejet à tort de l'hypothèse nulle de UR.

On peut souhaiter limiter en priorité le risque de rejeter à tort l'absence de UR. Pour cela, on inverse les hypothèses dans le test KPSS.

Inversion des hypothèses des tests de Dickey-Fuller :

$$\begin{cases} H_0 : X_t \text{ stationnaire} \\ H_1 : X_t \text{ non stationnaire} \end{cases}$$

Intérêt : vérifier la robustesse des conclusions du test de Dickey-Fuller augmenté.

Rappel : 4 situations possibles dans un test

		Réalité	
		H_0	H_1
Décision	D_0	$D_0 H_0$ Bonne décision	$D_0 H_1$ Erreur de 2nde espèce
	D_1	$D_1 H_0$ Erreur de 1ère espèce $P(D_1 H_0) = \alpha$	$D_1 H_1$ Bonne décision

Test de stationnarité de KPSS

Test basé sur la décomposition de X_t en

- 1 une composante déterministe f_t
 - $f_t = c$ si l'on vérifie la stationnarité en niveau
 - $f_t = c + bt$ Si l'on vérifie la stationnarité autour d'une tendance déterministe
- 2 un processus stochastique stationnaire u_t
- 3 une marche aléatoire $\tau_t = \tau_{t-1} + \varepsilon_t$ avec $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$

τ_t introduit de la non-stationnarité (stochastique) dans X_t

$X_t = c + \tau_t + u_t \Rightarrow$ stationnarité en niveau

$X_t = c + bt + \tau_t + u_t \Rightarrow$ stationnarité autour d'une tendance déterministe

Test de stationnarité de KPSS

La stationnarité ou pas de X_t dépend de $\tau_t = \tau_{t-1} + \varepsilon_t$ avec $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$
 si $\sigma_\varepsilon = 0$:

- $\varepsilon_t = 0, \forall t$
- $\tau_t = \tau_0$ se réduit à une constante
- X_t est alors stationnaire (autour d'une tendance déterministe si f_t contient une tendance déterministe)

si $\sigma_\varepsilon > 0$:

- $\tau_t = \tau_{t-1} + \varepsilon_t$ est une marche aléatoire
- X_t n'est pas stationnaire

Les hypothèses du test de stationnarité portent sur la valeur de σ_ε^2 :

$$\left\{ \begin{array}{l} H_0 : \sigma_\varepsilon = 0 \Rightarrow X_t \text{ stationnaire} \\ H_0 : \sigma_\varepsilon > 0 \Rightarrow X_t \text{ nonstationnaire} \end{array} \right.$$

Test de stationnarité de KPSS

- On estime le modèle $X_t = c + u_t$ ou $X_t = c + bt + u_t$ par les MCO
- On récupère le résidu $\hat{u}_t$
- On calcule la somme partielle des résidus $S_t = \sum_{i=1}^t \hat{u}_i$ et la variance de long-terme s^2 .
- L'expression de la statistique de test est

$$LM_{stat} = \frac{1}{s^2} \left(\frac{\sum_t S_t^2}{T^2} \right)$$

- On rejette l'hypothèse nulle de stationnarité (autour d'une tendance déterministe si $d_t = c + bt$) quand
 - la statistique de test LM_{stat} est supérieure au seuil critique
 - la probabilité critique est inférieure au risque de première espèce retenu

Application du test KPSS au PIB des Etats-Unis

Test de stationnarité KPSS avec constante et tendance déterministe

```

Régression KPSS
MCO, utilisant les observations 1990:1-2019:4 (T = 120)
Variable dépendante: l_GDP

      coefficient   erreur std.   t de Student   p. critique
-----
const    9,16501      0,00744259      1231          2,73e-244 ***
time     0,00607562    0,000106758      56,91         1,21e-087 ***

AIC: -426,96   BIC: -421,385   HQC: -424,696

Estimation robuste de la variance: 0,00780455
Somme des carrés des résidus cumulés: 59,6517

Test KPSS pour l_GDP (avec tendance)

T = 120
Paramètre du délai de troncation = 4
Statistique de test = 0,530777

      10%      5%      1%
Valeurs critiques: 0,120  0,148  0,216
P. critique < .01
    
```

Statistique du test KPSS = $LMstat = 0.5307$ supérieure aux seuils critiques pour $\alpha = 1\%, 5\%, 10\%$: on rejette l'hypothèse nulle de stationnarité autour d'une tendance déterministe

Application du test KPSS au PIB des Etats-Unis

Test de stationnarité KPSS avec constante

```
Régression KPSS
MCO, utilisant les observations 1990:1-2019:4 (T = 120)
Variable dépendante: l_GDP
```

	coefficient	erreur std.	t de Student	p. critique
const	9,53258	0,0196410	485,3	5,08e-198 ***

```

AIC: -27,1928  BIC: -24,4053  HQC: -26,0608

Estimation robuste de la variance: 0,2204
Somme des carrés des résidus cumulés: 7645,92

Test KPSS pour l_GDP

T = 120
Paramètre du délai de troncation = 4
Statistique de test = 2,4091

          10%      5%      1%
Valeurs critiques: 0,349  0,462  0,736
P. critique < .01

```

Statistique du test KPSS = $LMstat = 2.4091$ supérieure aux seuils critiques pour $\alpha = 1\%, 5\%, 10\%$: on rejette l'hypothèse nulle de stationnarité autour d'une constante